



Academia de Studii Economice
Facultatea de Cibernetică, Statistică și Informatică Economică

PROIECT PACHETE SOFTWARE

Profesor coordonator:
Andreescu Anca Ioana

Studenți:
Bostan Francesca-Maria
Bunduc Maria - Magdalena

1. Pachetul Python

1.1 Agregarea și Vizualizarea Datelor (Pandas & Streamlit)

a) Definirea problemei:

Agencia imobiliara doreste sa identifice cele mai profitabile cartiere din Bucuresti pentru deschiderea unei noi filiale. Pentru aceasta, trebuie sa aflam pretul mediu si numarul de oferte pentru fiecare zona.

b) Informații necesare pentru rezolvare:

Avem nevoie de setul de date stocat in fisierul extern Excel apartamente.xlsx, citit prin intermediul functiei `pd.read_excel()`, care contine variabilele: *Cartier*, *Pret_EUR* si *Suprafata_mp*.

c) Metode de calcul, algoritmi, formule de calcul utilizate:


Am utilizat pachetul *pandas* pentru gruparea datelor (*groupby*) in functie de cartier si functia de agregare *.agg()* pentru a calcula media preturilor si numarul de apartamente. Datele au fost afisate grafic folosind functia *st.bar_chart()* din Streamlit.

```
agregare_cartier = df_clean.groupby('Cartier').agg(  
    Pret_Mediu_EUR=('Pret_EUR', 'mean'),  
    Suprafata_Medie=('Suprafata_mp', 'mean'),  
    Nr_Oferte=('Pret_EUR', 'count')  
) .reset_index().sort_values(by='Pret_Mediu_EUR', ascending=False)  
  
st.dataframe(agregare_cartier)  
  
st.subheader("Grafic: Pretul mediu per cartier")  
st.bar_chart(data=agregare_cartier.set_index('Cartier')['Pret_Mediu_EUR'])
```

d) Prezentarea rezultatelor:

Cartier	Pret_Mediu_EUR	Suprafata_Medie	Nr_Oferte
2 Floreasca	280000	125.0867	3
4 Pipera	210000	127.5	4
1 Drumul Taberei	81666.6667	71.6667	3
0 Berceni	75000	56.6667	3
5 Titan	70666.6667	63.3333	3
3 Militari	50000	46.3333	3

Grafic: Pretul mediu per cartier



e) Interpretarea economică a rezultatelor:

Analiza indica zonele cu cel mai ridicat pret mediu per proprietate (de ex. Floreasca, Pipera). O agentie care vizeaza comisioane mari din tranzactii premium ar trebui sa se extinda in aceste cartiere. In schimb, cartierele cu cele mai multe oferte (volum mare) pot sustine o strategie bazata pe cantitatea vanzarilor.

f) Enunț, date, cod, interpretare, rezultate:

Am rezolvat problema analizării prețurilor pe cartiere, folosind setul de date imobiliare. Codul aplică funcții de grup și metode grafice de afișare, rezultând un top al cartierelor, ceea ce ajută managementul să decidă direcția de extindere a afacerii.

1.2. Regresia Multiplă (Statsmodels)

a) Definirea problemei:

Dorim să determinăm în ce măsură factorii structurali (suprafața, numărul de camere, anul construcției) influențează direct prețul de vânzare al unui apartament.

b) Informații necesare pentru rezolvare:

Variabila dependentă (Y) este *Pret_EUR*. Variabilele independente (X) sunt *Suprafata_mp*, *Nr_Camere*, *An_Constructie*.

c) Metode de calcul, algoritmi, formule de calcul utilizate:

Am utilizat pachetul *statsmodels* pentru a estima un model de regresie liniară multiplă (OLS - Ordinary Least Squares). Modelul adaugă o constantă (intercept) și calculează coeficienții pentru fiecare variabilă.

Echivalentul matematic este: $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \varepsilon$

```
X_sm = df_clean[['Suprafata_mp', 'Nr_Camere', 'An_Constructie']]
X_sm = sm.add_constant(X_sm)
y_sm = df_clean['Pret_EUR']

model_sm = sm.OLS(y_sm, X_sm).fit()

col_sm1, col_sm2 = st.columns(2)
col_sm1.metric("R-squared", f"{model_sm.rsquared:.2f}")
with st.expander("Vezi coeficienții modelului OLS"):
    st.write(model_sm.params)
```

d) Prezentarea rezultatelor:

R squared
0.48

Vezi coeficienții modelului OLS	
	0
const	-5740768.8065
Suprafata_mp	-1421.351
Nr_Camere	76326.4846
An_Constructie	2897.4638

e) Interpretarea economică a rezultatelor:

Coeficientul pozitiv al suprafeței arată suma (în euro) cu care crește valoarea proprietății pentru fiecare metru pătrat suplimentar. R-squared (Acuratețea) ne indică ce procent din variația prețului este explicată de acești factori. Dacă agenția vrea să evalueze rapid un apartament nou intrat în portofoliu, poate folosi acești coeficienți ca formulă standard de evaluare.

f) Enunț, date, cod, interpretare, rezultate:

Utilizând datele structurale ale apartamentelor, am aplicat modelul OLS din statsmodels. Rezultatele (coeficienții și R-squared) ne demonstrează că suprafața și anul construcției sunt predictorii puternici pentru preț, informație utilă în politica de stabilire a prețurilor agenției.

1.3. Machine Learning: Clusterizare (Scikit-Learn)

a) Definirea problemei:

Agenția dorește să împartă portofoliul de apartamente în "segmente de piață" (ex: buget, standard, lux) pentru a crea strategii de marketing personalizate.

b) Informații necesare pentru rezolvare:

Variabilele scalate *Suprafata_mp_Scalat* și *Pret_EUR*.

c) Metode de calcul, algoritmi, formule de calcul utilizate:

Am folosit algoritmul nesupervizat K-Means din pachetul scikit-learn. Am setat numărul de clustere la 3 (`n_clusters=3`). Înainte de clusterizare, datele au fost standardizate folosind *StandardScaler* (pentru a elimina discrepanțele de magnitudine între preț și metri pătrați).

```
col_ml1, col_ml2 = st.columns(2)

with col_ml1:
    st.subheader("A. Clusterizare (K-Means)")

    X_kmeans = df_clean[['Suprafata_mp_Scalat', 'Pret_EUR']]
    kmeans = KMeans(n_clusters=3, random_state=42, n_init=10)
    df_clean['Segment_Piata'] = kmeans.fit_predict(X_kmeans)

    fig, ax = plt.subplots()
    sns.scatterplot(data=df_clean, x='Suprafata_mp', y='Pret_EUR', hue='Segment_Piata', palette='viridis', ax=ax)
    st.pyplot(fig)

with col_ml2:
    st.subheader("B. Regresie Logistică")


    pret_mediu_general = df_clean['Pret_EUR'].median()
    df_clean['Este_Premium'] = (df_clean['Pret_EUR'] > pret_mediu_general).astype(int)

    X_log = df_clean[['Suprafata_mp_Scalat', 'Distanța_Metrou_m_Scalată', 'Cartier_Codificat']]
    y_log = df_clean['Este_Premium']

    try:
        X_train, X_test, y_train, y_test = train_test_split(X_log, y_log, test_size=0.25, random_state=42)
        model_log = LogisticRegression()
        model_log.fit(X_train, y_train)
        y_pred = model_log.predict(X_test)
        acuratete = accuracy_score(y_test, y_pred)
        st.metric("Acuratețea regresiei logistice", f"{acuratete * 100:.1f}%")
    except Exception as e:
        st.error("Setul de date este prea mic pentru antrenarea regresiei logistice pe set de testare.")
```

d) Prezentarea rezultatelor:

A. Clusterizare (K-Means)



e) Interpretarea economică a rezultatelor:

Algoritmul a identificat automat 3 tipologii de produse. Agenția poate alocă agenți de vânzări diferiți: un departament pentru segmentul de masă (apartamente mici/ieftine) și un departament "Premium" pentru segmentul de lux, eficientizând astfel costurile de marketing.

f) Enunț, date, cod, interpretare, rezultate:

Am segmentat clienții/ofertele în 3 grupuri folosind *K-Means* pe baza suprafeței și prețului. Rezultatul vizual (scatter plot) arată clar separarea pieței, oferind agenției o direcție clară pentru targetarea clienților.

2. Pachetul SAS

2.1. Procesare Iterativă, Condițională și Utilizarea de Formate

a) Definirea problemei:

Dorim să prognozăm valoarea apartamentelor din portofoliu pe următorii 3 ani, luând în calcul o apreciere anuală a pieței de 5%. De asemenea, dorim să clasificăm apartamentele pe categorii de preț și spațiu.

b) Informații necesare pentru rezolvare:

Avem nevoie de setul de date brut importat din fișierul extern Excel apartamente.xlsx utilizând procedura *PROC IMPORT* (cu opțiunea *dbms=xlsx*), conținând *Pret_EUR*, *Suprafata_mp* și *An_Constructie*.

c) Metode de calcul, algoritmi, formule de calcul utilizate:

Am creat un format definit de utilizator (*PROC FORMAT*) pentru a eticheta prețurile. Am calculat vechimea cu funcțiile *YEAR(TODAY())*. Pentru prognoza financiară, am utilizat procesarea iterativă (*DO loop de la 1 la 3*) combinată cu utilizarea de masive (*ARRAY Pret_Estim[3]*), aplicând formula de dobândă compusă ($Pret \times 1.05$). Condițiile de spațiu au fost delimitate prin instrucțiuni *IF-THEN/ELSE*.

```
proc format;
  value pret_fmt
    low - 75000 = 'Accesibil (<75k EUR)'
    75001 - 150000 = 'Mediu (75k - 150k EUR)'
    150001 - high = 'Premium (>150k EUR)';
run;

data apartamente_procesat;
  set apartamente;

  Vechime_Ani = YEAR(TODAY()) - An_Constructie;

  if Suprafata < 50 then Tip_Spatiu = 'Mic';
  else if Suprafata <= 80 then Tip_Spatiu = 'Optim';
  else Tip_Spatiu = 'Spatios';

  array Pret_Estim[3] Pret_An1 Pret_An2 Pret_An3;
  Pret_Curent_Temp = Pret_EUR;

  do i = 1 to 3;
    Pret_Estim[i] = Pret_Curent_Temp * 1.05;
    Pret_Curent_Temp = Pret_Estim[i];
  end;

  drop i Pret_Curent_Temp;
run;
```

d) Prezentarea rezultatelor:

	ID_Ap	Cartier	Suprafata	Nr_Camere	An_Constructie	Pret_EUR	Vechime_Ani	Tip_Spatiu	Pret_An1	Pret_An2	Pret_An3
1	1	Berceni	55	2	1980	65000	46	Opt	68250	71662.5	75245.625
2	2	Pipera	90	3	2020	180000	6	Spe	189000	198450	208372.5
3	3	Militari	45	1	2010	50000	16	Mic	52500	55125	57881.25
4	4	Floresca	120	4	2015	350000	11	Spe	367500	385875	405168.75
5	5	Titan	65	2	1975	70000	51	Opt	73500	77175	81033.75
6	6	Drumul Taberei	70	3	1985	85000	41	Opt	89250	93712.5	98398.125
7	7	Berceni	50	2	2005	75000	21	Opt	78750	82687.5	86821.875
8	8	Pipera	110	4	2022	250000	4	Spe	262500	275625	289406.25

e) Interpretarea economică a rezultatelor:

Prognoza prețurilor pe 3 ani ajută agenția să consilieze investitorii imobiliari. Dacă un investitor cumpără azi, agenția îi poate prezenta estimarea de creștere a capitalului (randamentul investiției de 5% pe an), încurajând astfel achizițiile pe termen lung.

f) Enunț, date, cod, interpretare, rezultate:

Prin pasul *DATA*, s-au aplicat funcții, array-uri și procesare condițională asupra setului importat. Rezultatul este un set de date îmbogățit cu prognoze și categorii, vital pentru strategiile investiționale.

2.2. Combinarea Seturilor de Date (PROC SQL) și Creare Subseturi

a) Definirea problemei:

Pentru o evaluare a riscurilor, dorim să combinăm datele despre apartamente cu informații specifice fiecărui cartier (riscul seismic și distanța față de centru) și să extragem doar apartamentele "Premium".

b) Informații necesare pentru rezolvare:

Două seturi de date separate: *apartamente_procesat* și *info_cartiere*. Variabila comună de legătură este *Cartier*.

c) Metode de calcul, algoritmi, formule de calcul utilizate:

S-a folosit procedura *PROC SQL* aplicând un *LEFT JOIN* pentru a aduce informațiile externe despre cartier la nivel de apartament. Ulterior, s-a creat un subset de date prin clauza *WHERE Pret_EUR > 150000*;

```
proc sql;
    create table analiza_completa as
    select a.*, i.Risc_Seismic, i.Distanța_Centru_km
    from apartamente_procesat as a
    left join info_cartiere as i
    on a.Cartier = i.Cartier;
quit;
```

```
data portofoliu_premium;
    set analiza_completa;
    where Pret_EUR > 150000;
    Categorie_Pret = put(Pret_EUR, pret_fmt.);
run;
```

d) Prezentarea rezultatelor:

Work.portofoliu_premium

	ID_Ap	Cartier	Suprafata	Nr_Camere	An_Constructie	Pret_EUR	Vechime_Ani	Tip_Spatiu	Pret_An1	Pret_An2	Pret_An3	Risc_Seismic	Distanța_Centru_km	Categorie_Pret
1	4	Floresca	120	4	2015	350000	11	Spa	367500	388875	405168.75	Sczut		4 Premium (>150k EUR)
2	2	Pipera	90	3	2020	180000	6	Spa	189000	190450	205372.5	Sczut		10 Premium (>150k EUR)
3	8	Pipera	110	4	2022	250000	4	Spa	262500	275625	289406.25	Sczut		10 Premium (>150k EUR)

Work.analiza_completa

	ID_Ap	Cartier	Suprafata	Nr_Camere	An_Constructie	Pret_EUR	Vechime_Ani	Tip_Spatiu	Pret_An1	Pret_An2	Pret_An3	Risc_Seismic	Distanța_Centru_km
1	1	Serceni	55	2	1980	65000	46	Opt	66250	71662.5	73245.625	Mediu	5
2	7	Serceni	50	2	2005	75000	21	Opt	78750	82687.5	86821.875	Mediu	5
3	6	Drumul Taberei	70	3	1985	85000	41	Opt	89250	93712.5	98398.125	Ridicat	6
4	4	Floresca	120	4	2015	350000	11	Spa	367500	388875	405168.75	Sczut	4
5	3	Milteni	45	1	2010	50000	16	Mic	52500	55125	57881.25	Mediu	9
6	2	Pipera	90	3	2020	180000	6	Spa	189000	190450	205372.5	Sczut	10
7	8	Pipera	110	4	2022	250000	4	Spa	262500	275625	289406.25	Sczut	10
8	5	Titan	65	2	1975	70000	51	Opt	73500	77175	81033.75	Mediu	7

e) Interpretarea economică a rezultatelor:

Asocierea riscului seismic cu valoarea apartamentului este esențială pentru polițele de asigurare și pentru negocierea prețului. Crearea subsetului "Premium" permite echipei de vânzări să se concentreze exclusiv pe clienții cu bugete mari, oferindu-le proprietăți care se află în zone cu risc scăzut și aproape de centru.

f) Enunț, date, cod, interpretare, rezultate:

Am îmbinat tabelul de proprietăți cu cel de infrastructură folosind SQL și am izolat portofoliul scump. Rezultatul este o bază de date consolidată, gata pentru rapoartele finale destinate managementului.

2.3. Raportare și Vizualizare (PROC REPORT, PROC MEANS, PROC SGPLOT)

a) Definirea problemei:

Managerul agenției solicită un raport sumarizat, statistici exacte și un grafic vizual care să arate relația dintre suprafață și preț în funcție de locație.

b) Informații necesare pentru rezolvare:

Setul complet și curățat *analiza_completa*.

c) Metode de calcul, algoritmi, formule de calcul utilizate:


- *PROC REPORT*: pentru generarea unui tabel agregat pe grupuri (cartiere).
- *PROC MEANS*: pentru statistici descriptive (Min, Max, Media).
- *PROC SGPLOT*: pentru a genera un grafic de dispersie (*scatter*), setând variabilele pe axe și utilizând gruparea prin culori.

```
title "Raport Apartamente: Detalii Portofoliu Complet";
proc report data=analiza_completa nowd;
  column Cartier Suprafata Nr_Camere Vechime_Ani Pret_EUR;
  define Cartier / group "Cartier";
  define Suprafata / mean "Suprafata Medie (mp)";
  define Pret_EUR / mean "Pret Mediu (EUR)" format=NLNUM12.2;
run;

title "Statistici Descriptive pentru Pret si Suprafata";
proc means data=analiza_completa N MEAN MIN MAX MAXDEC=2;
  class Tip_Spatiu;
  var Pret_EUR Suprafata;
run;

title "Relatia dintre Suprafata si Pret per Cartier";
proc sgplot data=analiza_completa;
  scatter x=Suprafata y=Pret_EUR / group=Cartier markerattrs=(symbol=CircleFilled size=12);
  xaxis label="Suprafata (mp)";
  yaxis label="Pretul (EUR)";
run;
title;
```


d) Prezentarea rezultatelor:



e) Interpretarea economică a rezultatelor:

Graficul de dispersie confirmă vizual că o creștere a suprafeței generează o creștere a prețului, dar panta (încălinația) diferă de la cartier la cartier. Apartamentele situate mai sus pe axa Y, deși au aceeași suprafață cu altele, arată prima (premium-ul) de locație (ex: Pipera/Floreasca vs Berceni). Aceasta justifică economic prețurile mai mari cerute pe zonele exclusiviste.

f) Enunț, date, cod, interpretare, rezultate:

Utilizând procedurile de raportare și grafică din SAS, am transpus datele brute în dashboard-uri și statistici. Rezultatele finale oferă o viziune completă, de ansamblu, susținând decizia de extindere a afacerii în cartierele care prezintă o dinamică pozitivă între suprafață și profitabilitate.